

Enjeux et méthodes de la reproductibilité scientifique

Lino Galiana 

Insee


29 mai 2026

Insee 
Mesurer pour comprendre

Contexte

- “**Crise de la reproductibilité**” durable dans la recherche
 - Ioannidis (2005), Chang et Li (2017), Kapoor et Narayanan (2023)...
 - Enjeu similaire dans l’industrie avec le problème du mur de la production (Davenport et Malone 2021)
- Facteurs multiples:
 - Acculturation et incitations limités aux enjeux de reproductibilité ;
 - Auditabilité limitée avec des données non partageables ;
 - Complexification des projets avec un accès aux données par le biais de multiples fournisseurs ou infrastructures ;
 - Recours à des logiciels propriétaires difficiles à auditer...
- Mouvement de la **science ouverte** et **politique plus active des revues scientifiques** pour plus de transparence


Exemple: la politique de l'AEA



Frise empruntée à Colliard et al. (2023)

Plus de détails récents, dans [AEA Data and code sharing policy](#)  et Vilhuber et Cavanagh (2025)

L'échelle de la reproductibilité




Source: Peng (2011)

- Une reproductibilité parfaite est coûteuse
- **Git** est un standard atteignable et efficient


Partage et transparence des données

- Beaucoup de **données non partageables** (secret industriel, confidentialité...)
 - France : accès simplifié aux données pour les chercheurs avec le CASD
- Approches à plusieurs niveaux :
 - Partage du protocole de collecte (sciences expérimentales)
 - Données synthétiques
 - Tiers de confiance (**Pérignon et al. 2019**)
- Sujet de **bonnes pratiques** dans le format des données sources et intermédiaires
 - ~~Excel~~ ●, CSV ●, Parquet ●
- Si la réplique n'est pas toujours possible, on peut au moins **viser la reproductibilité**

Le début des problèmes



Le premier pas



Partage et transparence du code

Niveau 0: versionner et partager son code

- **Git** , la première des bonnes pratiques:
 - Fiabilise l'évolution d'un projet avec du code
 - Oblige à se poser la question des bonnes pratiques
 - Permet de gérer la temporalité complexe d'un projet de recherche (tests, retours en arrière, etc.)
- **Github**  et l'*open source*, une démarche de transparence scientifique:
 - Partager son code de manière proactive en améliore la qualité
 - Possibilité de recevoir des feedbacks améliore la qualité
 - Galerie pour valoriser un projet

Partage et transparence du code

Premier niveau: lisibilité du code

“Le code est plus souvent lu qu’utilisé”. Guido Van Rossum

- Un **outil de communication** de la méthodologie
 - et de réplique de celle-ci (ex : *package*  d'économétrie)
- **Conventions communautaires** : *tidyverse style guide* () , *PEP8* et *PEP257* ()
- **Outils simples** pour mettre en oeuvre : les *formatters*
 - Très communs en . Le meilleur : **ruff**
 - Moins utilisés en  mais utiles. Le nouveau venu : **Air**

Partage et transparence du code

Deuxième niveau: lisibilité de la structure

Plus de détails dans un cours de mise en production de l'ENSAE ([Avouac et Galiana 2025](#))

- report.ipynb
- correlation.png
- data.csv
- data2.csv
- fig1.png
- figure 2 (copy).png
- report.pdf
- partial data.csv
- script.py
- script_final.py

- data
 - raw
 - dpe_logement_202103.csv
 - dpe_logement_202003.csv
 - interim
 - dpe_logement_merged_preprocessed.csv
- notebooks
 - report.ipynb
- src
 - main.R
 - preprocessing.R
 - generate_plots.R
- reports
 - report.pdf
- figures
 - histogram_energy_diagnostic.png
 - barplot_consumption_pcs.png
 - correlation_matrix.png
 - correlation.png


Partage et transparence du code

Troisième niveau: d'où vient ce chiffre ?

- **Git** , la première des bonnes pratiques
 - Mais ne suffit pas lorsqu'on a plus du code dans un projet
- “*Literate programming*” (Knuth 1984) = mélanger texte et code:
 - Jongler entre le code et le papier dans *L^AT_EX*: source d'erreur
 - **Jupyter notebook** : intéressant (Perkel 2018) mais potentiels problèmes de reproductibilité (Samuel et Mietchen 2023).
 - Meilleur outil : **Quarto** !

Partage et transparence de la configuration

Un projet lisible, structuré et versionné suffit-il à assurer la reproductibilité ?



It works on my machine

Partage et transparence de la configuration

- De nombreux **éléments d'environnement** peuvent faire qu'un code est non répliquable:
 - Environnement logiciel, secrets d'authentification, etc.
 - Certains sont partageables, d'autres non (ex: jetons d'API )
 - (Auto)documenter dans le code (variables d'environnement et **.env** ou **.Renviron**)
- Solution 1 : **environnements virtuels**
 - Recette de construction de l'environnement permettant de faire tourner le code
 - Solution technique: **venv** ou **uv** () , **renv** en ()
- Solution 2: la **conteneurisation**
 - Partager la recette de construction de l'ordinateur ayant permis de faire tourner le code (solution technique: **Docker** )
 - Plutôt orienté utilisation industrielle mais intéressant pour certains projets de recherche

Conclusion

- On a des **outils techniques** à utiliser pour résoudre la crise de la reproductibilité:
 - Socle minimal est atteignable simplement,
 - Etapes suivantes selon les projets.
- Mais aussi et surtout une **démarche à adopter**
- Aux **bénéfices nombreux**:
 - Moindre coût de maintenance,
 - Plus de transparence, de réutilisation...

Références

- Avouac, Romain, et Lino Galiana. 2025. *Mise en production de projets data science*. Cours à l'ENSAE. <https://doi.org/10.5281/zenodo.17486259>.
- Chang, Andrew C., et Phillip Li. 2017. « A Preanalysis Plan to Replicate Sixty Economics Research Papers That Worked Half of the Time ». *American Economic Review* 107 (5): 60-64. <https://doi.org/10.1257/aer.p20171034>.
- Colliard, Jean-Edouard, Christophe Hurlin, et Christophe Pérignon. 2023. « The economics of computational reproducibility ». *HEC Paris Research Paper No. FIN-2019-1345*.
- Davenport, Thomas, et Katie Malone. 2021. « Deployment as a Critical Business Data Science Discipline ». *Harvard Data Science Review* 3 (1).
- Ioannidis, John PA. 2005. « Why most published research findings are false ». *PLoS medicine* 2 (8): e124.
- Kapoor, Sayash, et Arvind Narayanan. 2023. « Leakage and the reproducibility crisis in machine-learning-based science ». *Patterns* 4 (9).
- Knuth, D. E. 1984. « Literate Programming ». *The Computer Journal* 27 (2): 97-111. <https://doi.org/10.1093/comjnl/27.2.97>.
- Peng, Roger D. 2011. « Reproducible research in computational science ». *Science* 334 (6060): 1226-27.

- Pérignon, Christophe, Kamel Gadouche, Christophe Hurlin, Roxane Silberman, et Eric Debonnel. 2019. « Certify reproducibility with confidential data ». *Science* 365 (6449): 127-28.
- Perkel, Jeffrey M. 2018. « Why Jupyter is data scientists' computational notebook of choice ». *Nature* 563 (7732): 145-47.
- Samuel, Sheeba, et Daniel Mietchen. 2023. *Computational reproducibility of Jupyter notebooks from biomedical publications*. <https://arxiv.org/abs/2308.07333>.
- Vilhuber, Lars, et Jack Cavanagh. 2025. « Report of the AEA Data Editor ». *AEA Papers and Proceedings* 115 (mai): 944-57. <https://doi.org/10.1257/pandp.115.944>.